Relatório de Projeto de Capstone em Ciência de Dados

Análise Preditiva de Pouso do Falcon 9 - SpaceX

Danieli Queiroz

GitHub: https://github.com/danieli-queiroz

Resumo Executivo

- Objetivo: Prever se o primeiro estágio do Falcon 9 vai pousar com sucesso, reduzindo custos de lançamento.
- Dados: 90 lançamentos do Falcon 9 coletados via API SpaceX e web scraping.
- Taxa de sucesso geral: 66.7% dos pousos foram bem-sucedidos.
- Métodos: Coleta de dados (API + Scraping), SQL, EDA, Visualização Interativa (Folium + Plotly Dash), Machine Learning.
- Melhor modelo: Logistic Regression, SVM e KNN empatados com 83.3% de acurácia no teste.
- Conclusão: A taxa de sucesso melhora ao longo do tempo. Locais KSC LC-39A apresentam maior taxa de sucesso.
- Aplicação: Empresas concorrentes podem estimar custos de lançamento com base na probabilidade de reutilização.

GitHub: https://github.com/danieli-queiroz

Introdução - Contexto e Problema

- A SpaceX revolucionou a indústria espacial ao reutilizar o primeiro estágio do foguete Falcon 9.
- Um lançamento do Falcon 9 custa ~62 milhões USD vs 165+ milhões de outros provedores.
- A economia vem da capacidade de pousar e reutilizar o booster (primeiro estágio).
- Problema: Podemos prever se o primeiro estágio pousará com sucesso?
- Se sim, concorrentes podem estimar custos reais de um lançamento SpaceX.
- Este projeto aplica o ciclo completo de Data Science: coleta, limpeza, análise exploratória, visualização e modelagem preditiva.

Coleta de Dados - API SpaceX

- Fonte: API REST SpaceX v4 (https://api.spacexdata.com/v4/launches)
- Endpoints utilizados: /launches, /rockets, /launchpads, /payloads, /cores
- Processo: Requisição GET → JSON → Normalização → DataFrame Pandas
- Resultado: 90 lançamentos Falcon 9 até Nov/2020
- Dados extraídos: FlightNumber, Date, BoosterVersion, PayloadMass, Orbit, LaunchSite, Outcome, etc.
- Tratamento: Valores nulos de PayloadMass preenchidos com a média.

Fluxo: API Request → JSON Parse → DataFrame → Filter Falcon 9 → Feature Engineering → Clean Data

GitHub: https://github.com/danieli-queiroz

Coleta de Dados - Web Scraping

- Fonte alternativa: Wikipedia - Lista de lançamentos Falcon 9 e Falcon Heavy
- Biblioteca: BeautifulSoup para parsing HTML
- Dados extraídos: Tabelas de lançamentos com datas, locais, payloads e resultados
- Processo: Request HTML → Parse com BeautifulSoup → Extrair tabelas → DataFrame
- Complementa dados da API com informações adicionais de missões
- Validação cruzada entre dados da API e do scraping para consistência

Fluxo: HTTP GET Wikipedia → BeautifulSoup Parse → Extract Tables → Clean → DataFrame

GitHub: https://github.com/danieli-queiroz

Metodologia de Tratamento de Dados

- Filtragem: Removidos lançamentos Falcon 1, mantidos apenas Falcon 9
- Variável alvo (Class): 1 = pouso bem-sucedido, 0 = falha no pouso
- Outcomes classificados como falha: False ASDS, False RTLS, None ASDS, None RTLS
- Tratamento de nulos: PayloadMass preenchido com média dos valores existentes
- One-Hot Encoding: Variáveis categóricas convertidas para features numéricas
- Padronização: StandardScaler aplicado em todas as features para ML
- Split: 80% treino, 20% teste (random_state=2 para reprodutibilidade)

GitHub: https://github.com/danieli-queiroz

EDA com Visualização de Dados

Gráficos gerados para explorar relações entre variáveis e identificar padrões:

- Gráficos de Dispersão: FlightNumber vs PayloadMass, PayloadMass vs LaunchSite
- Gráficos de Barras: Taxa de sucesso por órbita, Lançamentos por site
- Gráfico de Linha: Tendência anual da taxa de sucesso
- Gráficos de Pizza: Taxa de sucesso geral e por site de lançamento

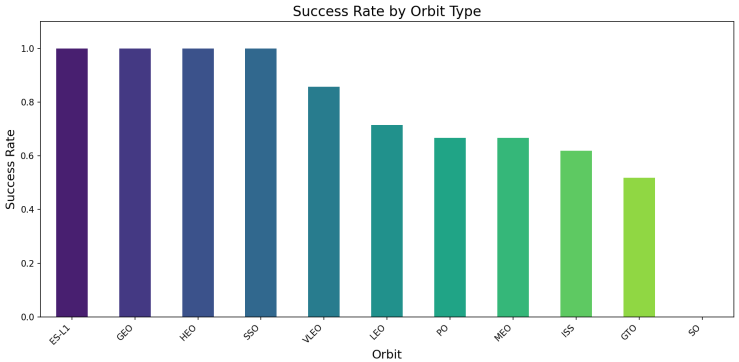

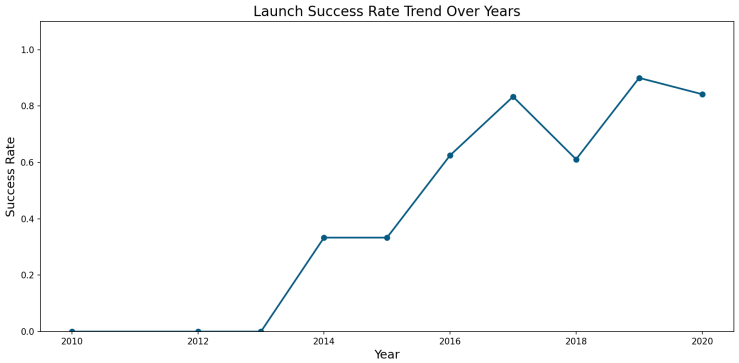

GitHub: https://github.com/danieli-queiroz

Resultados EDA - Gráficos de Dispersão

Relação entre número do voo, massa de carga útil e resultado do pouso por site de lançamento.

Observa-se que voos mais recentes (maior FlightNumber) tendem a ter mais sucesso.

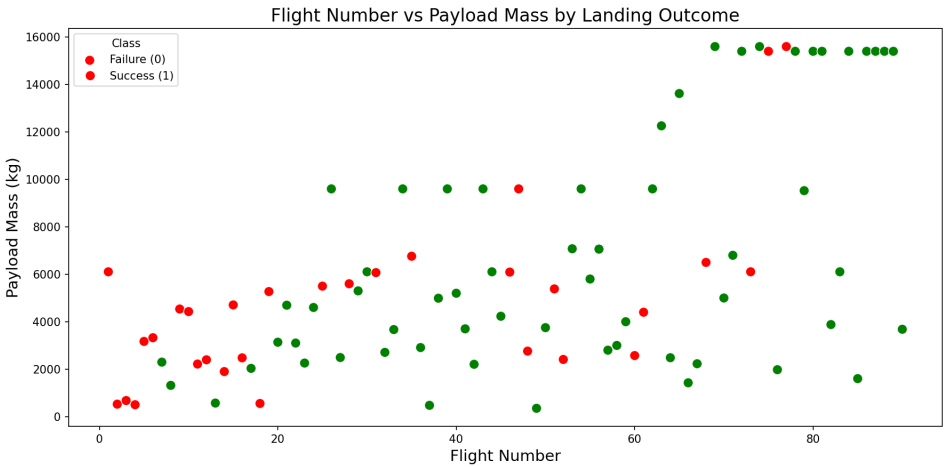

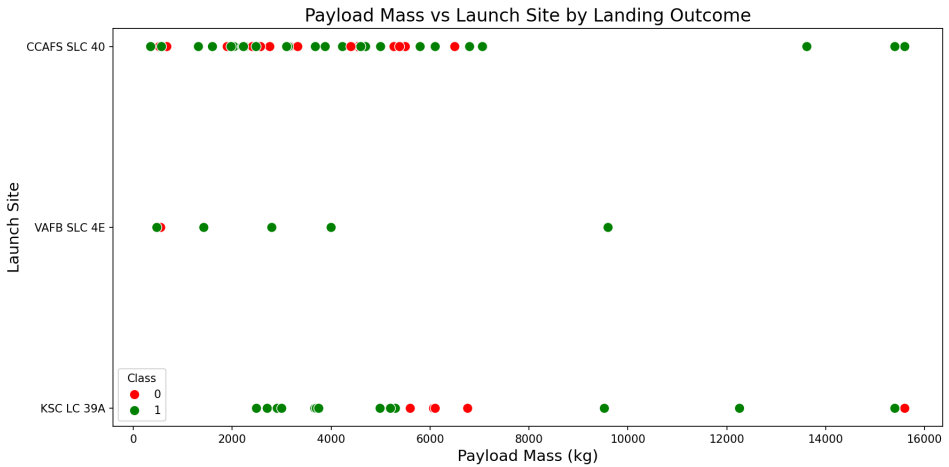

Resultados EDA - Barras e Tendências Anuais

Esquerda: Distribuição de lançamentos por site. Direita: Tendência de sucesso ao longo dos anos.

A taxa de sucesso cresceu significativamente a partir de 2013, atingindo ~100% nos anos recentes.

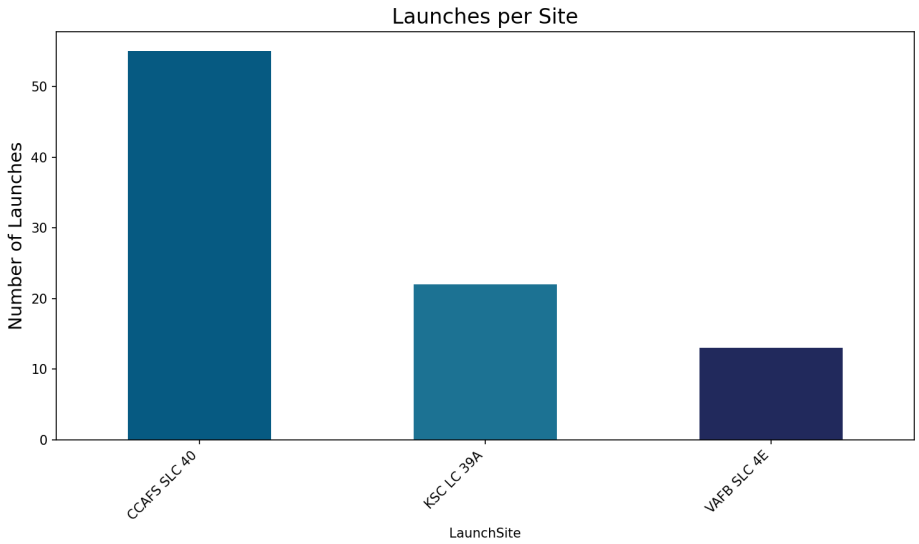

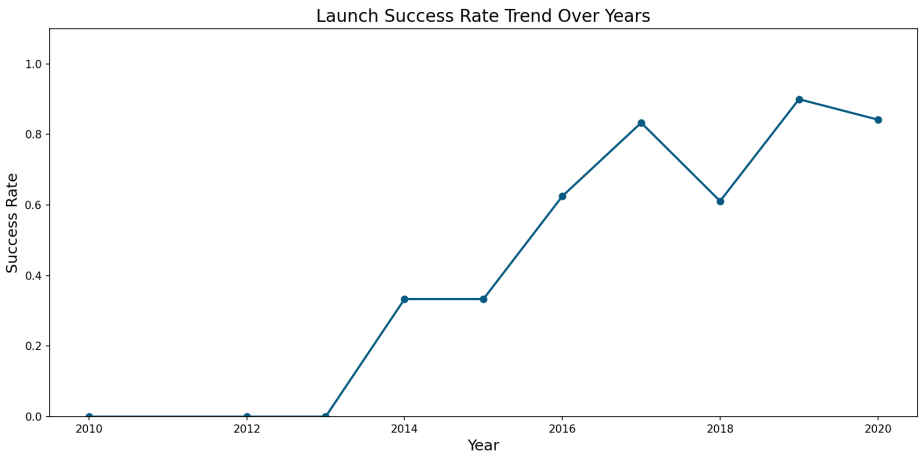

Resultados EDA - Pizza de Sucesso

Taxa de sucesso global: 66.7%. KSC LC-39A tem a maior taxa de sucesso entre os sites.

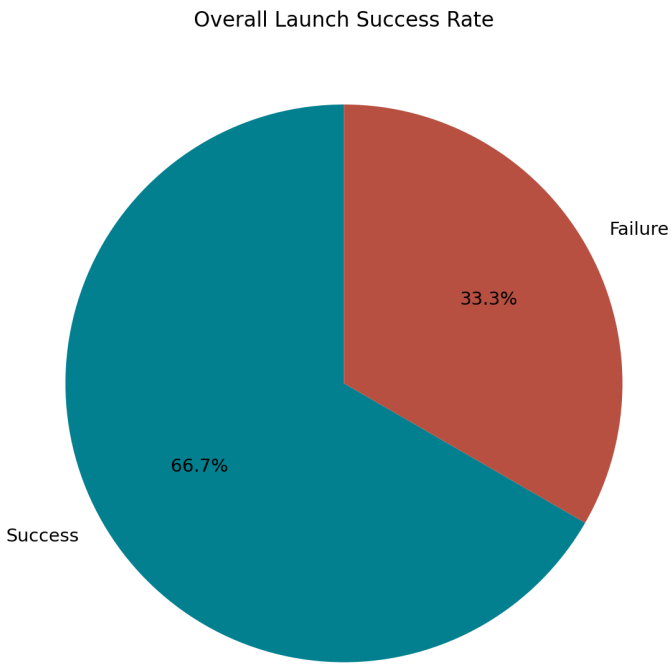

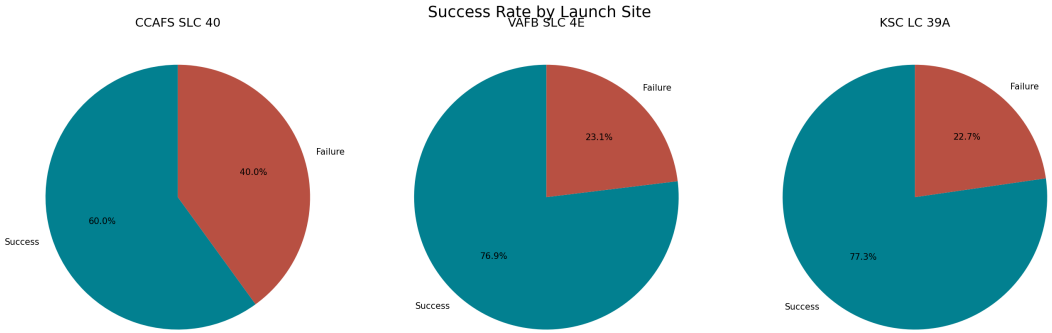

EDA com SQL

- **Sites únicos de lançamento**

```
SELECT DISTINCT Launch_Site FROM SPACEXTBL
```

- **Payload total por site**

```
SELECT Launch_Site, SUM(PAYLOAD_MASS__KG_) FROM SPACEXTBL GROUP BY Launch_Site
```

- **Primeiro pouso em terra**

```
SELECT MIN(Date) WHERE Landing_Outcome LIKE '%Success%Ground%'
```

- **Boosters com sucesso (drone, 4-6k kg)**

```
SELECT Booster_Version WHERE Success Drone AND Payload 4000-6000
```

- **Resultados de pouso 2010-2017**

```
SELECT Landing_Outcome, COUNT(*) ... BETWEEN 2010-2017
```

- **Max payload e booster version**

```
SELECT Booster_Version, MAX(PAYLOAD_MASS__KG_)
```

GitHub: https://github.com/danieli-queiroz

Resultados das Consultas SQL

- 4 sites de lançamento: CCAFS LC-40, CCAFS SLC-40, KSC LC-39A, VAFB SLC-4E
- CCAFS SLC-40 tem o maior payload total: 254.037 kg
- Primeiro pouso bem-sucedido em terra: 22/12/2015
- Boosters com sucesso drone (4-6k kg): F9 FT B1022, B1026, B1021.2, B1031.2
- Max payload: 15.600 kg (múltiplos B5 boosters)
- 2010-2017: 10 tentativas sem pouso, 5 sucessos em drone ship, 3 em ground pad
- Resultado geral: 98 missões com sucesso, 1 falha em voo

GitHub: https://github.com/danieli-queiroz

Análise Visual Interativa - Folium e Plotly Dash

- Mapa Folium: Marcadores nos sites de lançamento com coordenadas GPS
- Clusters: Marcadores coloridos (verde=sucesso, vermelho=falha) agrupados por região
- Análise de proximidade: Distâncias calculadas entre sites e costa, rodovias, ferrovias e cidades
- CCAFS SLC-40: ~0.87 km da costa, próximo a infraestrutura de transporte
- Plotly Dash: Aplicativo interativo com gráficos de pizza por site e scatter de payload vs sucesso
- Permite filtrar por site de lançamento e faixa de payload dinamicamente

Ferramentas: Folium (mapas), Plotly Dash (dashboard interativo)

GitHub Folium: https://github.com/danieli-queiroz

GitHub Dash: https://github.com/danieli-queiroz

Mapa Folium - Locais de Lançamento

- Sites identificados: CCAFS LC-40, CCAFS SLC-40, KSC LC-39A (Florida), VAFB SLC-4E (California)
- Todos os sites da Florida estão na costa atlântica, próximos ao Cabo Canaveral
- VAFB está na costa do Pacífico, usado para órbitas polares
- Marcadores verde/vermelho mostram padrão: sites mais recentes têm mais sucesso
- Análise de proximidade revela estratégia de localização perto de infraestrutura
- Sites escolhidos por: proximidade costeira (segurança), latitude (eficiência orbital), logística

Plotly Dash - Gráficos Interativos

Dashboard com: Pie chart de sucesso por site | Scatter de payload vs sucesso por site

KSC LC-39A lidera em taxa de sucesso. Payloads leves e pesados têm sucesso similar.

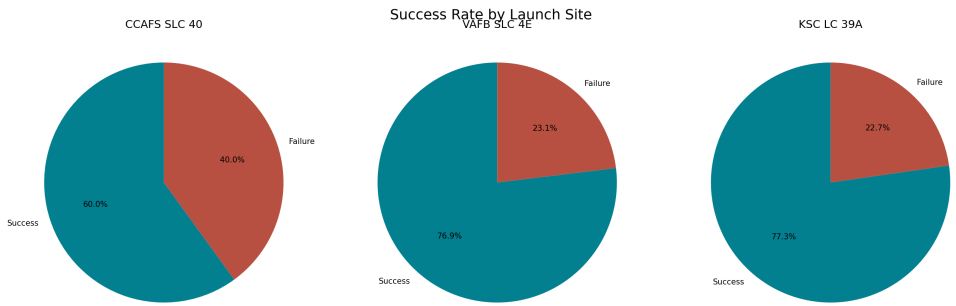

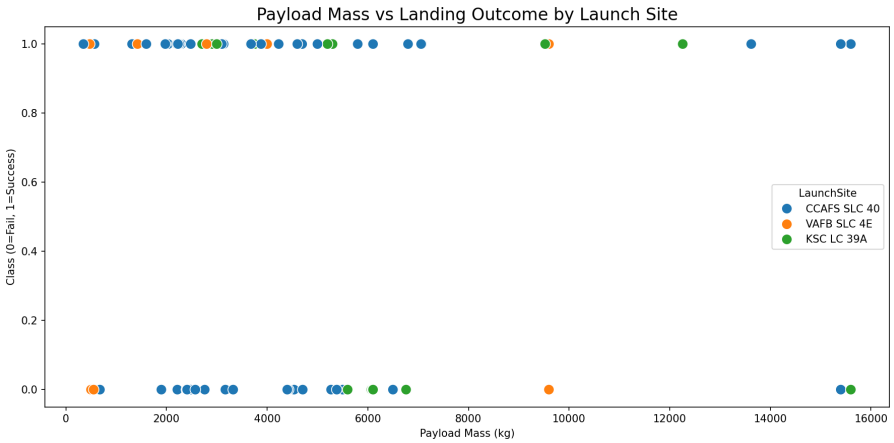

Análise Preditiva - Múltiplos Modelos

4 algoritmos de classificação treinados com GridSearchCV (10-fold CV):

Modelo	Melhores Parâmetros	CV Score	Test Score
Logistic Regression	{'C': 0.01, 'penalty': 'l2', 'solver': 'lbfgs'}	0.8464	0.8333
SVM	{'C': np.float64(1.0), 'gamma': np.float64(0.03162...	0.8482	0.8333
Decision Tree	{'criterion': 'gini', 'max_depth': 14, 'min_sample...	0.8714	0.7778
KNN	{'algorithm': 'auto', 'n_neighbors': 10, 'p': 1}	0.8482	0.8333

Matrizes de Confusão - Todos os Modelos

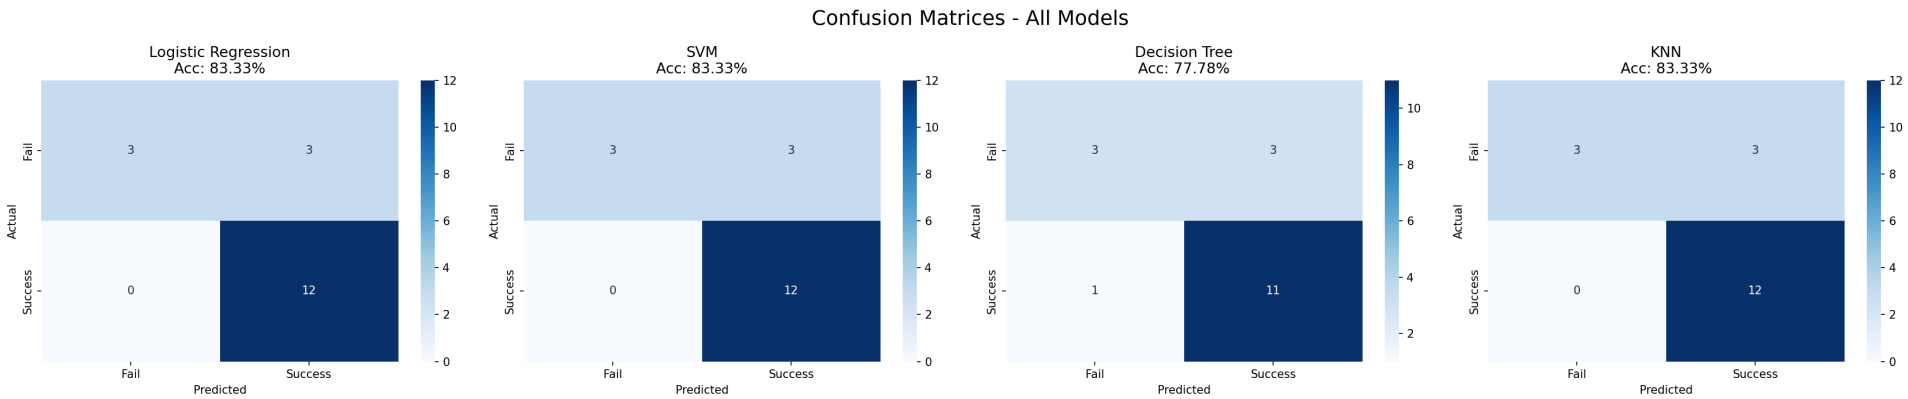

Comparação de Modelos

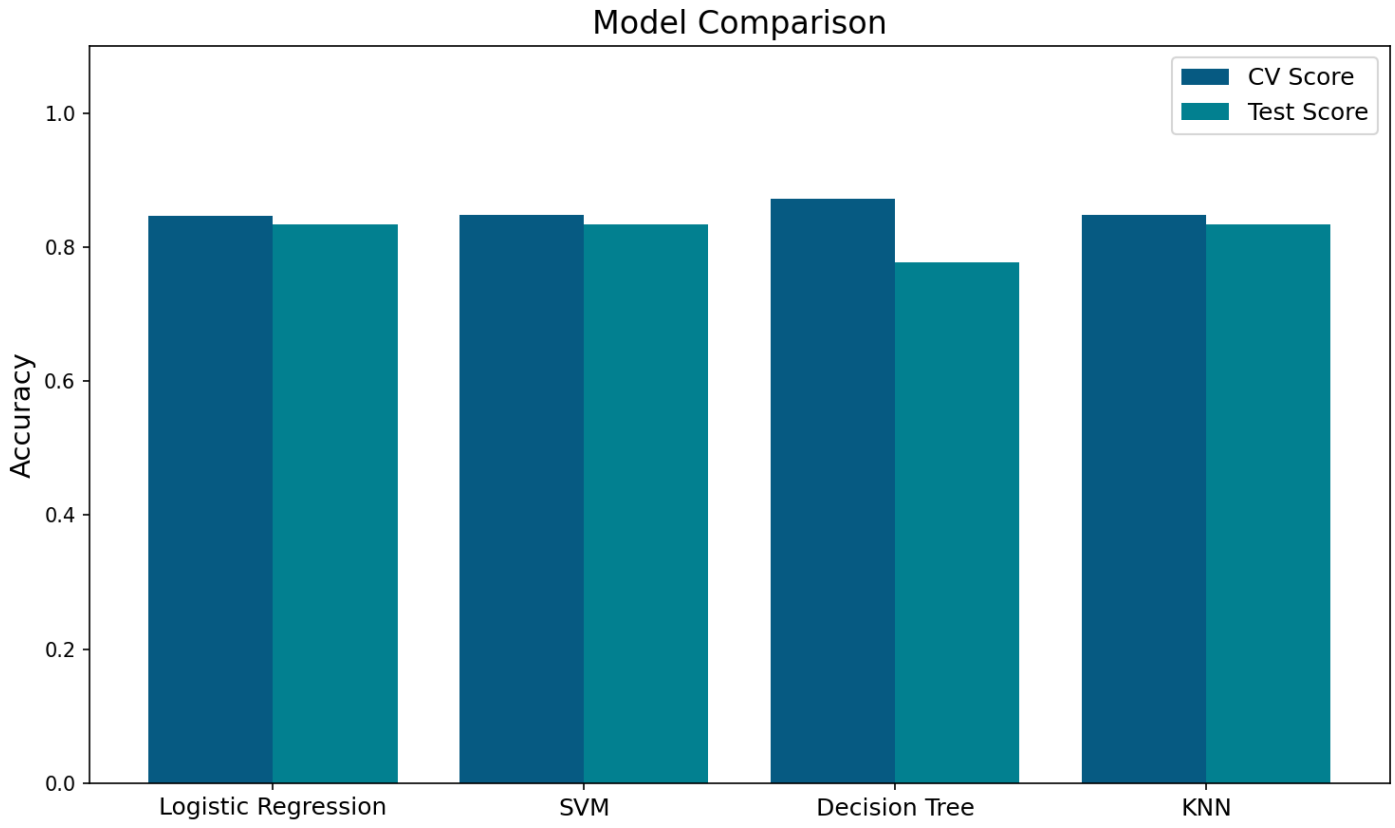

Melhor Modelo e Explicação

- Logistic Regression, SVM e KNN empataram com 83.33% de acurácia no teste.
- Decision Tree teve menor acurácia no teste (77.78%), indicando overfitting.
- Logistic Regression é o modelo recomendado por: simplicidade, interpretabilidade e eficiência.
- Parâmetros ótimos (LR): {'C': 0.01, 'penalty': 'l2', 'solver': 'lbfgs'}
- O modelo é capaz de prever com boa acurácia se o booster pousará com sucesso.
- Limitação: Dataset pequeno (90 lançamentos, 18 no teste) pode limitar generalização.

Conclusão

- A taxa de sucesso do Falcon 9 melhorou drasticamente ao longo do tempo (de 0% para ~100%).
- KSC LC-39A é o site com melhor desempenho de pouso.
- Órbitas LEO e ISS apresentam as maiores taxas de sucesso.
- Logistic Regression é o modelo recomendado: 83.33% de acurácia, simples e interpretável.
- Insights: PayloadMass, FlightNumber e LaunchSite são fatores-chave para previsão de pouso.
- Aplicação: Concorrentes podem usar modelos similares para estimar custos de lançamento SpaceX.

■ Insight Inovador

A reutilização de boosters não é apenas uma inovação tecnológica - é um modelo de negócio disruptivo que reduz o custo de acesso ao espaço em ~70%, democratizando a exploração espacial.